

Reporte de implementación y experimentos

Calidad de los datos

Se estableció un catalogo en el que se dispone de cuatro fuentes de información provenientes de las áreas de Crédito y Cartera, así como de Registro y Control. A partir de estas fuentes, se desarrolló el catálogo y el diccionario correspondientes a la solución analítica para la predicción de la morosidad en créditos estudiantiles.

En el catálogo se describe el dominio de negocio del cual provienen los datos y la fuente específica de cada conjunto de información. Asimismo, se documenta el formato en que los datos son actualmente compartidos y utilizados para la construcción del modelo predictivo, lo que garantiza una adecuada trazabilidad, así como una comprensión clara del origen y la estructura de la información empleada en el desarrollo del proyecto.

Base de datos	Descripción	Origen de negocio	Fuente Origen	Frecuencia de actualización	Nivel de sensibilidad	Formato
CRq - Créditos Financieros	Contiene información relacionada con las condiciones del crédito, incluyendo montos, número de cuotas, tasas, estados y fechas de desembolso.	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
CCq - Cartera edades cliente	Complementa la caracterización del crédito y refuerza la estimación de riesgo a nivel individual.	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
Matriz total - Scoring de riesgo	Este conjunto permite identificar la evolución del cumplimiento de pagos y controlar las variaciones dependientes del crédito (mora o mora).	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
MAI	Contiene variables provenientes del proceso de validación crediticia, incluyendo verificaciones de identidad, preanálisis, ingresos, gastos, nivel de endeudamiento y datos socioeconómicos.	Tercero	Plataforma ROMBO	Mensual	Confidencial	xlsx
Validación cartera	Este conjunto constituye la base para las variables financieras y de comportamiento que alimentan el modelo predictivo.	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
TD	Incluye información académica y demográfica de todos los estudiantes desde 2001 hasta 2020: cohorte, programa, facultad, tipo de estudiante, estrato socioeconómico, nivel académico y datos de matrícula.	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
DIEMPOLA	Permite caracterizar el perfil del beneficiario y analizar la relación entre factores académicos y probabilidad de mora.	Cartera	Plataforma ROMBO	Mensual	Confidencial	xlsx
	Contiene la información de los municipios y departamentos de Colombia	NA	Datos abiertos Gov	Anual	Pública	xlsx

Tabla 1. Diccionario de datos

Asimismo, se llevó a cabo una evaluación de la calidad de los datos, considerando las principales dimensiones de calidad: exactitud, completitud, consistencia, integridad, razonabilidad, oportunidad, unicidad y validez. De estas, se priorizaron tres dimensiones —completitud, exactitud y validez—, las cuales fueron definidas en conjunto con los stakeholders del proyecto, dado su impacto directo en la confiabilidad del modelo analítico.

Las reglas de calidad correspondientes a cada dimensión fueron definidas, documentadas e implementadas, asegurando así la consistencia y trazabilidad del proceso de evaluación. Toda esta información se encuentra disponible en el repositorio oficial del proyecto en GitHub, el cual centraliza la documentación y los artefactos generados durante el desarrollo.

Reglas de calidad					
Base de datos	Descripción	Número de regla	Dimensión	Variable	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 1	Completitud	Periodo, Actualización	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 2	Completitud	Linea	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 3	Completitud	Nombre, Area	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 4	Completitud	Fecha, aprobación	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 5	Completitud	Cliente	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 6	Completitud	Nombre, Rendo	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 7	Completitud	No, credito	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 8	Completitud	Valor, financiación	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 9	Completitud	Cuotas	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 10	Completitud	Tipo, interes	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 11	Completitud	Estado, credito	
CRq - Créditos Financieros	No debe tener valores nulos o vacíos	pt. 12	Completitud	Saldo, credito	
CRq - Créditos Financieros	Los primeros 4 dígitos deben ser entre 2020 y año mayor al año actual	pt. 13	Exactitud	Periodo, Actualización	
CRq - Créditos Financieros	El texto debe ser de 6 dígitos	pt. 14	Validez	Periodo, Actualización	
CRq - Créditos Financieros	El texto debe ser de 2 dígitos	pt. 15	Validez	Linea	
CRq - Créditos Financieros	Debe ser una fecha válida	pt. 16	Validez	Fecha, aprobación	
CRq - Créditos Financieros	El año de la fecha de aprobación no debe ser 2 años menor al periodo de facturación	pt. 17	Consistencia	Fecha, aprobación	
CRq - Créditos Financieros	El texto debe ser numérico	pt. 18	Validez	No, credito	
CRq - Créditos Financieros	El texto debe ser numérico	pt. 19	Validez	Valor, financiación	
CRq - Créditos Financieros	El texto debe ser numérico	pt. 20	Validez	Cuotas	

Tabla 2. Reglas de Calidad

A continuación, se presentan los resultados obtenidos para cada una de las bases de datos, luego de la aplicación y verificación de las reglas de calidad definidas para cada dataset.

CRq - Créditos Financieros

En total, se evaluaron 13 campos mediante la implementación de 23 reglas de calidad, clasificadas en las siguientes dimensiones:

Dimensión	Cantidad reglas	Resultado
Completitud	12	100%
Exactitud	1	100%
Validez	9	99.8%
Consistencia	1	100%

Tabla 3. Calidad base CRq- Créditos Financieros

Los resultados obtenidos reflejan un alto nivel de calidad de los datos, con porcentajes de cumplimiento de 100 % en completitud, exactitud y consistencia, y 99,8 % en validez. En conjunto, el archivo alcanza una calidad global del 99,9 %.

No obstante, se identificó una regla de calidad que necesita revisión correspondiente a la validación de que “el valor de financiación sea mayor que 0 y no supere el 85 % del valor total de la matrícula (‘Vr_net_maturcula’)”. En esta regla, de los 71.493 registros analizados, 812 presentan incumplimiento, por lo que se recomienda su análisis detallado y la definición de las acciones de remediación correspondientes.

CCq - Cartera edades cliente

En total, se evaluaron 13 campos mediante la implementación de 26 reglas de calidad, clasificadas en las siguientes dimensiones:

Dimensión	Cantidad reglas	Resultado
Completitud	13	100%
Consistencia	1	100%
Validez	12	100%

Tabla 4. Calidad base CCq – Cartera edades

Los resultados obtenidos evidencian que la información seleccionada para la construcción del modelo analítico cumple en un 100 % con todas las reglas de calidad definidas, garantizando así la confiabilidad y consistencia de los datos utilizados en el desarrollo del modelo predictivo.

Matriz total - Scoring de riesgo

En total, se evaluaron 26 campos mediante la implementación de **44 reglas de calidad**, clasificadas en las siguientes dimensiones:

Dimension	Cantidad reglas	Resultado
Compleitud	26	96.4%
Exactitud	1	100%
Validez	17	95.7%

Tabla 5. Calidad base Scoring de riesgo

Los resultados obtenidos reflejaron un alto nivel de calidad de los datos, con porcentajes de cumplimiento de 100 % en exactitud, 96,4 % en completitud y 95,7 % en validez. En conjunto, el archivo alcanza una calidad global del 96,2 %, lo que evidencia una adecuada consistencia y confiabilidad en la información analizada.

No obstante, se identificaron algunas reglas con incidencias principalmente asociadas a las dimensiones de completitud y validez.

En cuanto a la completitud, las reglas pf_4 a pf_10, pf_14 y pf_23 a pf_25 presentaron incumplimientos relacionados con los campos: Valor_cuota_inicial, Valor_Primer_Cuota, Fecha_de_pago, Dirección, Ciudad, Departamento, Validación_valor_financiado, Tipo_de_estudiante, Valor_máximo, Valor_medio y Valor_bajo.

Por su parte, en la dimensión de validez, las reglas pf_30 a pf_36 y pf_39 evidenciaron fallos en las siguientes verificaciones:

- El valor de la cuota inicial debe ser tipo float y mayor a 0.
- El valor de la primera cuota debe ser tipo float y mayor a 0.
- La fecha de pago debe ser un número mayor o igual a 1 y menor o igual a 30.
- Las ciudades deben contener únicamente caracteres alfabéticos (A–Z).
- Los departamentos deben contener únicamente caracteres alfabéticos (A–Z).
- El valor financiado debe ser tipo float y mayor a 0.
- El detalle del estado final debe corresponder a uno de los siguientes valores: “Desembolsado”, “Aprobada en preanálisis y análisis sin desembolsar”, “Aprobado completo” o “Aprobado incompleto”.
- El tipo de estudiante debe contener únicamente caracteres alfabéticos (A–Z).

MAFI

En total, se evaluaron 19 campos mediante la implementación de **27 reglas de calidad**, clasificadas en las siguientes dimensiones:

Dimension	Cantidad reglas	Resultado
Compleitud	19	96.8%
Exactitud	1	99.9%
Validez	7	89.6%

Tabla 6. Calidad base MAFI

Los resultados obtenidos reflejan un buen nivel de calidad de los datos, con porcentajes de cumplimiento de 99,9 % en exactitud, 96,8 % en completitud y 89,6 % en validez. En conjunto, el archivo alcanza una calidad global del 91,4 %, lo que evidencia una consistencia y confiabilidad adecuadas en la información analizada.

No obstante, los resultados también indicaron la necesidad de revisar y tratar cada uno de los campos evaluados, dado que ninguna de las reglas de calidad alcanzó un cumplimiento del 100 %, lo cual sugiere la presencia de valores o registros que requieren procesos adicionales de limpieza o validación antes de su utilización en el modelo analítico.

A nivel global, **la calidad de las bases de datos alcanzó un 96,8 %**, lo que representa un indicador positivo del estado general de la información. Sin embargo, a partir de estos resultados se identifica la necesidad de definir e implementar reglas de limpieza o remediación de datos que permitan corregir las inconsistencias detectadas y asegurar que la información cumpla plenamente con los estándares requeridos antes de proceder con el desarrollo de cualquier modelo analítico o predictivo.

Por lo que con esto previo al proceso de limpieza, se realizó una revisión general del estado de las bases para evaluar su completitud, consistencia, claridad y formato. Se identificó que algunos campos presentan valores faltantes que requerirán métodos de imputación, mientras que la estructura general de la información muestra coherencia entre las definiciones de los campos y los datos registrados. Asimismo, se verificó que las variables permiten obtener resultados estadísticos interpretables, aspecto que se profundizará en el EDA. Finalmente, se detectaron inconsistencias de formato como valores numéricos leídos como texto que deberán estandarizarse durante el proceso de limpieza y preparación del dataset analítico.

Técnicas de limpieza de datos

El proceso de limpieza y remediación de datos se desarrolló como una etapa fundamental para garantizar que la información utilizada en el modelado cumpliera con los estándares de completitud, coherencia, claridad y formato requeridos para un análisis confiable.

Tras la evaluación inicial de calidad, se identificaron diversos aspectos que podían comprometer la integridad analítica de las bases, como valores faltantes, inconsistencias, tipos de dato incorrectos, respuestas fuera de rango y posibles interrelaciones entre campos, lo cual hizo necesario aplicar un conjunto estructurado de reglas de limpieza.

Estas reglas fueron implementadas y documentadas en el repositorio oficial del proyecto el cual también se encuentra como anexo, con el propósito de asegurar trazabilidad, reproducibilidad y control sobre cada transformación realizada.

Durante esta fase también se verificó la presencia de valores extremos aceptados por la institución y la existencia de columnas redundantes que debían resolverse mediante selección o estandarización. Con base en este diagnóstico, se estableció un conjunto de técnicas orientadas a depurar, transformar y validar los datos, preparando así un dataset íntegro y consistente para las etapas posteriores de análisis exploratorio y modelado predictivo.

Para el entendimiento de los datos, se tomó como referencia el marco metodológico propuesto por INFORMS, el cual establece nueve técnicas fundamentales para el análisis y comprensión de los datos. A continuación, se detallan cada una de estas técnicas y los principales hallazgos obtenidos a partir de su aplicación.



Filtración

Durante la fase de entendimiento de los datos, se identificaron, para cada una de las bases analizadas, los registros y campos que debían ser filtrados con el fin de conservar únicamente la información de los créditos internos y la posterior construcción del modelo predictivo. A partir de este proceso, se definieron los siguientes **filtros específicos por base** de datos:

- **CRq - Créditos Financieros:** se conservaron los registros donde el campo Línea se encuentra entre los valores 42 y 55, correspondientes a créditos internos. Se excluyeron los casos con Vr_neto_matricula nulo, ya que indican créditos no iniciados, y se filtraron los registros del campo Estado_credito conservando únicamente los valores “Cancelado” y “En Cartera”, debido a que los demás presentan inconsistencias para el cálculo de la variable objetivo (Y).
- **Matriz Total - Scoring de Riesgo:** se seleccionaron los registros con la categoría Cate igual a “Sello Financiero” y “Crédito aprobado” que hacen referencia al scoring de los créditos aprobados.
- **MAFI:** se eliminaron las filas sin registros de IDBANNER y sin información en el campo FECHA_NACIMIENTO y aquellas con menos de seis campos diligenciados.
- **CCq - Cartera Edades Cliente:** se conservaron únicamente los registros con el valor “118/19 CARGO DE LA FINANCIACIÓN MATRÍCULAS” que hacen refencia a las cuentas contables a las que cae el concepto de crédito interno

Imputación

Durante la etapa de limpieza y exploración de las bases fuentes se aplicaron imputaciones determinísticas basadas en reglas de negocio, con el fin de corregir inconsistencias operativas sin alterar la distribución estadística de los datos. Estas imputaciones corresponden a variables cuyo valor puede inferirse directamente de la lógica del proceso académico, financiero y de cartera

- Imputación de variables como Estado_civil, Grupo etnico y Tipo de discapacidad, en que aparecen como valores nulos y se realiza imputación categorica dejando como “No declarado” para no incorporar información distorcionada que afectará al modelo.

- Dado que los registros en la base MAFI pertenecen a los diferentes periodos cursados por un estudiante, se realiza la imputación de nulos de Direcciones y Ciudades con el último periodo con información reportada.
- Se realiza imputación de los nulos en Sede según el programa académico, dado que hace referencia a Virtual o Bogotá en la medida que sea presencial
- imputación cruzada entre columnas complementarias como para las variables de Valor cuota inicial y Valor primera cuota
- Para la base de Scoring se realiza una imputación para los nulos de la variable Fecha de pago que hace referencia al día del mes que el cliente establece para realizar los pagos, esto extrayendola base de Cartera el día de la fecha de vencimiento e imputando los nulos.
- Posterior en la comlumna de Fecha de pago si quedan nulos se cruza con el último periodo con información reportada.
- En la columna de validación de valor financiado que hace referencia al Saldo mínimo del valor se realiza imputación por estudiante con el promedio de sus registros
- Las variables VALOR MÁXIMO, VALOR MEDIO y VALOR BAJO corresponden a información financiera obtenida directamente de Datacrédito, disponible únicamente en la nueva plataforma implementada desde 2024. Por esta razón, cerca del 30% de los registros históricos (créditos previos a 2024) no contienen estos valores. Dado que estos campos representan atributos reales del titular y no es posible inferirlos de otras fuentes internas sin introducir sesgo o falsos supuestos, se aplicó una imputación neutra con valor 0. Se deja la variable de la plataforma como bandera para estos faltantes

Posterior a las imputaciones determinísticas aplicadas en la fase de limpieza, el modelo incorpora un preprocesamiento estadístico que garantiza la consistencia y completitud de los datos tanto en el entrenamiento como en la predicción de nuevos registros. Para las variables numéricas se utilizó un imputador basado en la mediana, robusto frente a valores extremos, mientras que las variables categóricas se completan con la categoría más frecuente y posteriormente se codifican mediante OneHotEncoder, tolerando categorías nuevas.

La aplicación de estos métodos permitió manejar de manera controlada los valores faltantes o nulos, evitando sesgos en el análisis posterior y asegurando que cualquier valor faltante así como los nulos que aparezcan en el flujo de datos futuros, sean tratados de forma automática y reproducible.

Reducción de dimensionalidad

La reducción de dimensionalidad se aplicó con el objetivo de optimizar la estructura del dataset, eliminar información redundante o irrelevante y favorecer la eficiencia del modelo predictivo. Este proceso consistió en depurar variables que no aportaban valor analítico, presentaban vacíos generalizados a mas de un 90% o provenían de sistemas heredados, evitando así incorporar ruido o complejidad innecesaria.

En primer lugar, se eliminaron más de setenta (70) columnas asociadas a la versión anterior del sistema de scoring, las cuales no estaban disponibles en la plataforma actual ni tenían equivalencia directa, por lo que su uso generaría sesgos o inconsistencias para nuevos datos que ingresaran.

De igual forma, se descartaron múltiples variables constantes o sin variabilidad, especialmente aquellas que posterior a los filtros realizados de crédito interno quedaron como constantes (como Orden, info_basica, PILA_Cliente, OTP_Cliente, entre otras), que no ofrecían información diferenciadora para el modelo.

A manera de prueba y siguiendo prácticas de modelos predictivos implementados por instituciones educativas se evaluó si era pertinente incorporar técnicas estadísticas formales de reducción de dimensionalidad, como PCA. Se compararon rendimientos de modelos iniciales con y sin PCA utilizando únicamente las variables numéricas reales (Para esto se revisó que variables habían numéricas y se excluyeron las que se documentan como numericas pero en realidad son categoricas como: Año, Fecha de pago que es los días del mes que quiere pagar y la Mora que es booleano 1 y 0).

	PC1	PC2	PC3	PC4
Antigüedad_meses	-0.347052	0.006917	0.205270	0.914896
Valor_financiacion	0.246032	0.641182	-0.123418	0.101944
Cuotas	-0.064911	0.254025	0.935594	-0.236250
Vr_neto_matricula	0.245339	0.639115	-0.131043	0.131779
VALOR MAXIMO	0.501537	-0.196504	0.129260	0.162681
VALOR MEDIO	0.501539	-0.196505	0.129248	0.162649

Figura1. Componentes principales establecidos PCA




Figura 2. Varianza de componentes principales con PCA

El análisis de componentes principales evidenció que las variables numéricas no presentan correlaciones suficientes como para beneficiarse de una reducción de dimensionalidad. Los componentes generados agrupan únicamente el comportamiento socioeconómico (VALOR MÁXIMO, MEDIO y BAJO) y los valores financieros del crédito, mientras que variables como Cuotas y Antigüedad permanecen prácticamente aisladas en sus propios componentes.




Figura 3. Comparación de rendimiento del modelo con y sin PCA

De igual manera los resultados mostraron que para los modelos iniciales de prueba sin PCA se obtuvo un mejor desempeño en métricas críticas (AUC, precision y recall), especialmente en la identificación de las clases minoritarias de riesgo Alto y Medio.

Por estas razones, aun cuando se probó PCA como técnica de reducción dimensional, se concluyó en línea con las tendencias de modelos de riesgo estudiantil del sector que la mejor versión del modelo es la que no utiliza PCA, manteniendo únicamente la depuración de variables irrelevantes, constantes o con bajo aporte analítico.

Extracción de features

En esta etapa se construyeron nuevas variables que no existían originalmente en las fuentes y que permiten capturar mejor los factores asociados al riesgo de morosidad. Estas variables derivadas se diseñaron con base en reglas de negocio, cálculos financieros y relaciones temporales entre las bases.

- Entre las principales variables creadas se encuentran:
- Antigüedad_meses, que mide el tiempo de vida del crédito desde su aprobación.
 - Llave1 y Llave2, necesarias para garantizar la trazabilidad entre crédito, cartera, scoring y datos académicos.
 - Cuotas_vencidas y Cuotas_por_vencer, obtenidas mediante agrupación por Llave2 y clasificación por tipo de cartera.
 - Banderas de imputación, que permiten identificar diferencias estructurales entre versiones del sistema de scoring y manejar adecuadamente las inconsistencias heredadas.
 - Reconstrucción del valor financiado, donde se generó una estimación basada en el promedio histórico de cada estudiante ante la ausencia de datos completos en versiones previas.

Metodología para el cálculo de la variable objetivo (Y) como nueva variable.

Para definir la variable objetivo (Y) se acordó utilizar únicamente las cuotas vencidas y las cuotas por vencer, las cuales no forman parte del

modelo y se emplean temporalmente para calcular la variable respuesta. El cálculo se realizó mediante la siguiente expresión:

$$Y = \frac{\text{Cuotas vencidas}}{\text{Total de cuotas pactadas} - \text{Cuotas por vencer}}$$

Figura 4. Fórmula para el cálculo de la variable respuesta

Este planteamiento permitió excluir del cálculo todas las cuotas futuras que aún no han alcanzado su fecha de vencimiento, evitando distorsiones en la medición del comportamiento de pago y sesgos en la predicción.

Clasificación por niveles de riesgo (Y categorica)

A partir de la distribución de la variable Y continua, se crea la variable Y categórica a partir de la definición de tres niveles de riesgo de morosidad para segmentar los registros y facilitar el enfoque del modelo como un problema multiclase, acordados y validados con el stakeholder del área de Cartera:

Rango de Y_continua	Nivel de riesgo	Interpretación
0 a 0.20	Bajo	Comportamiento normal o sin mora. Pagos puntuales.
>0.20 a 0.25	Medio	Mora incipiente. Indicador de alerta temprana.
>0.25 a 1.00	Alto	Mora significativa o impago reiterado.

Tabla 7. Clasificación del riesgo para variable continua

Una vez calculada la variable Y, toda la información relacionada con la cartera fue eliminada del dataset final con el fin de impedir el ingreso de variables que reflejaran comportamientos posteriores al origen del crédito. Con base en esta definición, el dataset final incluyó únicamente variables de predicción válidas: características del crédito al origen, información académica, datos demográficos y el scoring externo, garantizando integridad y consistencia.

Descripción de variables estadísticas




Figura 5. Distribución en el df de la variable predictora

Tras la depuración del dataset y la eliminación de variables que pudieran reflejar comportamientos posteriores al origen del crédito, se examinó la distribución de la variable objetivo Y. El análisis mostró un desbalance marcado: la mayoría de los registros pertenecen a la categoría de riesgo Bajo, seguidos por una proporción menor en riesgo Alto y una fracción muy reducida en riesgo Medio. Esta distribución evidencia que los eventos de mayor severidad son menos frecuentes dentro de la población analizada.

A continuación, se revisó la matriz de correlación entre las principales variables numéricas y la codificación binaria asociada a la categoría Y_alto. Aunque las correlaciones lineales no alcanzan magnitudes elevadas, se observan agrupamientos entre variables de naturaleza financiera, como los valores relacionados con montos financiados, matrícula y cuotas. También se aprecia que variables temporales, como la fecha de aprobación y la antigüedad en meses, muestran patrones diferenciales respecto a la presencia de riesgo alto.





Figura 6. Matriz de correlación variable respuesta

El análisis se amplió incorporando la representación esparsa de variables categóricas mediante la codificación correspondiente, permitiendo generar una matriz de correlación extendida. En esta visualización surgen relaciones más estructuradas entre categorías de tipo de interés, cohorte académica, tipo de estudiante, carga académica y plataformas o modalidades asociadas al crédito. Estas variables presentan comportamientos diferenciados en torno a Y_alto, lo que sugiere que influyen en la forma en que se distribuyen los casos dentro de las distintas categorías de riesgo.

Adicionalmente, la presencia de bloques definidos dentro de la matriz extendida indica que algunas variables categóricas comparten patrones internos, reflejando similitudes operativas o académicas en la población estudiantil. La inclusión simultánea de variables numéricas y categóricas permitió obtener una visión más completa de la estructura del dataset refinado y de cómo ciertos grupos de características tienden a asociarse entre sí en función del comportamiento asociado a la variable Y.








Figura 8. Histogramas de variables numéricas por clase

En “Antigüedad_meses” los créditos de riesgo “Alto” se agrupan con mayor frecuencia en periodos iniciales, mientras que los de riesgo “Bajo” se distribuyen de manera más amplia a lo largo del tiempo. Un patrón similar se observa en “Cuotas”, donde los créditos de seis cuotas predominan en la clase “Bajo”, y los casos “Alto” tienen menor presencia dentro de cada modalidad. Estas diferencias, aunque sutiles debido al desbalance natural del dataset, muestran que ciertas configuraciones numéricas están asociadas a mayor o menor probabilidad de incumplimiento.

En las variables categóricas también se identifican diferencias claras entre los niveles de riesgo. Independientemente de la categoría analizada, ya sea tipo de interés, cohorte, cluster de programa o historial de mora, la proporción de casos “Bajo” supera sistemáticamente el 80 por ciento, mientras que “Alto” rara vez supera el 15 por ciento.

Sin embargo, algunas categorías revelan señales importantes, por ejemplo, “Anualidad Vencida” y el cluster de programa “Derecho” muestran porcentajes relativamente mayores de riesgo “Alto” en comparación con otras categorías, lo que sugiere grupos puntuales donde el riesgo se concentra.

La relación entre Y y las variables categóricas también muestra patrones consistentes respecto al comportamiento observado en la mora previa. La categoría “Sí” en mora histórica presenta una proporción más alta de riesgo “Alto” que la categoría “No”, lo que confirma la coherencia del comportamiento del dataset y la relevancia de este factor. En conclusión, los análisis numéricos y categóricos permiten identificar los segmentos con mayor propensión al incumplimiento y aportan información fundamental para sustentar el desarrollo de un modelo predictivo más preciso y alineado con el comportamiento real de la cartera.







Figura 9. Frecuencia variables categóricas por clase

Adición de nueva información

Se integró información geográfica adicional a las bases del modelo, específicamente latitud y longitud, adicionando la base DIVIPOLA que integra los códigos DANE de cada ciudad reportada por los estudiantes.

Esta incorporación se realizó mediante un cruce entre la variable CODCIUDAD y CIUDAD con las la base oficial del DANE, esta nueva información permitió:

- Completar valores faltantes de ciudad y codificación geográfica en la base MAFI y de Scoring, para la información reportada vacía o inconsistente.
- Homologar ciudades con diferentes formatos (tildes, abreviaturas, errores de digitación).
- Incorporar variables adicionales (latitud y longitud) que pueden ser útiles para análisis posteriores, como segmentación territorial, patrones de riesgo por ubicación o cruces con información socioeconómica externa.

Segmentación de los datos

Frente a la segmentación de la variable respuesta Y formulada con el acompañamiento de los Stakeholder, donde a partir de su conocimiento técnico en Cartera y frente al comportamiento de las cuotas se categorizaron en Riesgo alto, bajo y medio.

A partir de esta segmentación se realizó la inclusión de patrones, para identificar características claves del crédito, entre los análisis encontrados uno de ellos se enfocaron en la antigüedad de los créditos y el valor financiado encontrando:




Figura 10. Metodo del codo de Kmeans

- Los créditos más recientes concentran mayores señales de riesgo.
- Los estudiantes con financiaciones más altas muestran mayor vulnerabilidad.
- Los scores externos menos favorables coinciden con mayor probabilidad de incumplimiento.

Estos patrones no solo enriquecen la comprensión del comportamiento de la cartera, sino que también aportan una base sólida para justificar la inclusión de estas variables en el modelo predictivo. Además, esta segmentación complementa al análisis estadístico realizado y fortalece la alineación entre el modelo y el conocimiento operativo institucional.

De igual manera, con el propósito de complementar la segmentación basada en reglas de negocio, se realizó un análisis exploratorio de segmentación no supervisada mediante el algoritmo K-Means. Con el objetivo de identificar si los datos presentan agrupaciones naturales que permitieran detectar patrones estructurales en los créditos y, potencialmente, relacionarlos con el riesgo real observado.




Figura 11. Distribución por clusters

Los análisis de K-Means realizados sobre las variables numéricas del crédito permitieron identificar tres grupos naturales de financiamiento, diferenciados principalmente por la antigüedad del crédito, el monto financiado, el valor de matrícula y los niveles del scoring externo.

- Cluster 0: créditos relativamente recientes, con montos financiados más altos y valorizaciones elevadas en las variables del scoring externo.
- Cluster 1: créditos intermedios tanto en antigüedad como en valor financiado, y con puntuaciones de scoring externo moderadas.
- Cluster 2: créditos significativamente más antiguos, con mayor número de cuotas acumuladas y valores más bajos en las variables de scoring externo.

Estos clusters evidencian que se agrupan en créditos similares financieramente, no créditos similares en riesgo por lo que los grupos no se alinean con el comportamiento real de la mora.

Esto se debe a que K-Means segmenta únicamente con base en características numéricas y no incorpora los factores académicos, demográficos y conductuales que realmente explican el riesgo, y se encuentran en las variables categóricas.

Determinación de variables importantes

Previo al cálculo de importancia de variables, se realizó una depuración estructurada de la matriz original de atributos. La combinación de las cuatro bases contenían 212 variables, pero no todas aportaban información útil para el modelo. A través de un proceso de filtración, imputación, ingeniería de variables y eliminación de duplicados o atributos irrelevantes, se consolidó un conjunto final de 41 variables efectivamente utilizadas por el modelo (7 numéricas y 34 categóricas.) Esta reducción permitió eliminar ruido, disminuir la dimensionalidad y mejorar tanto el rendimiento como la interpretabilidad del modelo.

	Variable	Importancia
0	Cate	0.119461
1	Cuotas	0.106224
2	VALOR MEDIO	0.096119
3	Vr_neto_matricula	0.060064
4	VALOR MAXIMO	0.055661
5	Operación	0.054538
6	NACIONALIDAD	0.052761
7	Fecha_aprobacion	0.047741
8	Antigüedad_meses	0.045363
9	Valor_financiacion	0.044845




Figura 12. Importancia de variables

A parte de la determinación de variables de manera manual la cual encontrará en el catalogo de datos, se quiso realizar una exploración inicial con el algoritmo Random Forest, cuya capacidad para asignar importancia a cada variable permitió identificar cuáles factores influyen con mayor peso en la predicción del riesgo.

Las variables más relevantes incluyeron elementos financieros del crédito (como Cate, número de cuotas, valor de matrícula, valor financiado, y métricas del scoring externo), junto con variables académicas y demográficas tales como operación, nacionalidad, fecha de aprobación, estado civil, programa académico y tipo de estudiante.

Clasificación o agrupación

Aparte de la clasificación matemática realizada con el acompañamiento de los Stakeholders para la formulación de la variable de respuesta de clasificación, para el entendimiento inicial de los datos, también se exploraron técnicas de clasificación no supervisada, particularmente la agrupación mediante clustering, con el fin de identificar posibles segmentos naturales dentro de los créditos o estudiantes sin usar aún la variable objetivo. Este ejercicio permitió observar si existían patrones ocultos basados únicamente en las características numéricas del dataset, como valores financiados, número de cuotas, antigüedad del crédito o indicadores socioacadémicos.

Aunque estos agrupamientos no se alinearon directamente con los niveles de riesgo (debido a que algoritmos como K-Means solo operan con variables numéricas y no incorporan categorías críticas de negocio), sí contribuyeron a comprender la estructura interna de los datos, la distribución de las características y la posible existencia de subpoblaciones con comportamientos similares.

El proceso de limpieza permitió depurar, corregir y estandarizar las cuatro bases institucionales hasta obtener un conjunto de datos completo, consistente y libre de inconsistencias críticas. Las reglas aplicadas, incluyendo imputaciones, ajustes de formato, eliminación de valores inválidos y armonización entre fuentes, garantizaron que la información final fuera coherente con la naturaleza del problema de Analytics, centrado en la predicción del riesgo de mora por crédito estudiantil.

Gracias a esta depuración, los datos resultantes reflejan fielmente el comportamiento real del proceso crediticio y cumplen con los requisitos de calidad necesarios para avanzar hacia el análisis exploratorio, la construcción de variables y el modelado predictivo, asegurando así una base sólida y confiable para resolver la problemática planteada.

Elección de enfoques

La elección del enfoque analítico se fundamentó en el objetivo institucional de anticipar el riesgo de mora por crédito estudiantil y, al mismo tiempo, ofrecer una herramienta integral de apoyo para la toma de decisiones en las áreas de Crédito y Cartera. Esto implica combinar múltiples enfoques de Analytics que permitan comprender el fenómeno, predecirlo y, potencialmente, orientar acciones futuras.

Por lo que con el propósito de garantizar que cada técnica seleccionada aporte directamente a la gestión de cartera y la sostenibilidad financiera de la universidad. Se alinearon a los objetivos del análisis con su respuesta a cada uno.

Enfoque Descriptivo

Para este enfoque lo utilizamos en dos momentos para responder a los objetivos de análisis del comportamiento demográfico, académico y financiero de los estudiantes, así como para examinar la distribución de las variables y sus relaciones con la mora. Este enfoque utiliza técnicas como el análisis exploratorio de datos (EDA), correlaciones y visualizaciones estadísticas, que permiten identificar patrones relevantes tales como diferencias en el riesgo según estrato, jornada, facultad, montos financiados o historial de pagos.

Además, este enfoque descriptivo se materializa operacionalmente en un dashboard en Power BI, el cual no solo complementa el análisis del modelo predictivo, sino que también permite monitorear indicadores institucionales como el Recaudo de Cartera. Este visualizador facilita la interpretación del desempeño del modelo y provee una vista integral del sistema crediticio para la toma de decisiones.

Enfoque Predictivo

Se emplearon modelos supervisados de clasificación como Random Forest, XGBoost y LightGBM, los cuales permiten capturar relaciones complejas entre variables, gestionar desbalances en los datos y maximizar métricas críticas como el AUC y el Recall para los casos de mayor riesgo. Este enfoque se complementa con un proceso robusto de preprocesamiento y feature engineering, que incluyó estandarización, codificación, creación de ratios financieros y variables derivadas del comportamiento histórico, con el fin de mejorar la calidad de los datos y representar de manera más informativa los factores asociados al riesgo.

Adicionalmente, se aplican técnicas de selección e importancia de variables (feature selection) para identificar qué atributos son realmente determinantes en el incumplimiento, optimizando el rendimiento del modelo y fortaleciendo su interpretabilidad para el equipo de Cartera. Estos componentes de preparación y selección de variables son esenciales para garantizar que el modelo predictivo sea estable, preciso y alineado con la realidad operacional de la universidad.

Finalmente, aunque el proyecto no desarrolla aún un enfoque prescriptivo, la integración del dashboard con el modelo predictivo sienta las bases para futuras acciones de optimización, tales como priorización de gestiones, segmentaciones automáticas de créditos según nivel de riesgo y simulaciones de impacto sobre indicadores institucionales.

En conjunto, estos enfoques garantizan que el proyecto responda completamente a los objetivos establecidos, permitiendo comprender el fenómeno, predecirlo con precisión y habilitar a la institución para avanzar posteriormente hacia decisiones más estratégicas y basadas en datos.

Selección del metodo o técnica

Con el objetivo de seleccionar los enfoques y métodos analíticos que permiten responder a esta necesidad institucional. Se realiza elección fundamentada en los resultados de las fases anteriores: análisis de fuentes, evaluación de los datos, limpieza, establecimiento de criterios de éxito, riesgos y descripción del comportamiento histórico de la cartera. En coherencia con ello, la selección del método se orienta tanto por la naturaleza del problema como por el tipo de respuesta requerida para la toma de decisiones.

Tipo de enfoque requerido según la problemática de negocio

El problema planteado exigió un enfoque predominantemente predictivo, dado que la universidad necesita anticipar qué estudiantes tienen mayor probabilidad de incurrir en mora para priorizar esfuerzos de gestión, diseñar estrategias preventivas y fortalecer el recaudo oportuno. Sin embargo, este enfoque se complementa con un enfoque descriptivo, fundamental para analizar el comportamiento histórico de los créditos, caracterizar perfiles de riesgo, evaluar la distribución de la mora por cohortes y comprender la relación entre variables académicas, sociodemográficas y financieras.

En consecuencia, el proyecto integra ambos enfoques:

- **Descriptivo**, para entender qué está ocurriendo con la cartera y los estudiantes.
- **Predictivo**, para estimar el riesgo futuro de incumplimiento y habilitar modelos de alerta temprana.

Esta combinación aseguró que la solución planteada no solo prediga, sino que también contextualice los resultados, ofreciendo un valor analítico integral y útil para Cartera, Dirección Financiera y procesos institucionales.

Métodos y técnicas indicadas para responder al problema

A partir de estos enfoques, los métodos seleccionados corresponden a las técnicas que mejor se ajustan a los tipos de datos disponibles, al objetivo de predicción y a los requerimientos de interpretación del área usuaria. Entre las técnicas aplicadas se encuentran:

- **Técnicas estadísticas descriptivas:** análisis exploratorio, correlaciones, distribución de mora por cohortes, para identificar patrones diferenciadores entre estudiantes.
- **Herramientas de monitoreo y visualización:** integradas al modelo para dar seguimiento al impacto en el indicador institucional de Recaudo Cartera (línea base 85%).
- **Preprocesamiento y feature engineering y selection:** normalización, generación de ratios de capacidad de pago codificación de variables categóricas y determinar qué variables de las bases que son realmente predictoras del incumplimiento, optimizando el rendimiento del modelo.
- **Modelos de clasificación supervisados:** regresión logística, Random Forest, XGBoost. orientados a construir un modelo que estime la probabilidad de mora por estudiante y genere alertas tempranas.

Objetivo de análisis de datos	Técnica aplicada	Respuesta al objetivo
Construir un modelo supervisado que estime la probabilidad de mora por estudiante.	Modelos de clasificación supervisados (Random Forest, XGBoost, LighGBM)	Predicen la probabilidad de que un estudiante entre en mora, permitiendo generar alertas tempranas
Analizar las bases y determinar qué variables son realmente predictoras de incumplimiento.	Selección e importancia de variables (feature selection, importance scores)	Identifican los factores con mayor peso en el incumplimiento (ej. ingresos, estrato, historial de cartera), optimizando el modelo.
Analizar atributos demográficos y académicos que influyen en el riesgo de mora.	EDA y correlaciones	Muestran cómo características como edad, género, facultad o jornada se relacionan con la probabilidad de mora.
Monitorear el impacto del modelo sobre el indicador de Recaudo Cartera (línea base 85%).	Dashboard en Power BI integrado con el modelo	Visualiza el efecto del modelo sobre el recaudo oportuno y permite medir mejoras frente a la línea base institucional.

Tabla 8. Aplicación de técnicas por objetivos

Acciones de los enfoques

A partir de los enfoques seleccionados y de las técnicas definidas para el desarrollo del proyecto, se establecieron un conjunto de acciones específicas orientadas a resolver directamente la problemática de negocio: anticipar la mora por crédito estudiantil y fortalecer la gestión institucional de cartera.

Cada técnica aplicada, modelos supervisados, feature engineering y selección de variables, análisis descriptivo mediante EDA y la implementación de un dashboard en Power BI, permite intervenir un componente diferente del sistema crediticio, ya sea generando predicciones tempranas, ajustando políticas internas, identificando segmentos críticos o monitoreando el impacto del modelo en el indicador de recaudo.

A continuación, se presentan las acciones concretas que se derivan del uso de cada técnica, mostrando cómo cada una contribuyó de manera puntual y estratégica al logro de los objetivos del proyecto.

Modelos supervisados

- Implementar un sistema de alertas tempranas que priorice a los estudiantes con mayor riesgo de mora
- Incorporar la probabilidad de incumplimiento enfocados en modelos de cobranza preventiva

Feature engineering y selection

- Ajustar los criterios de aprobación de crédito, utilizando solo los factores realmente predictivos de incumplimiento.
- Rediseñar el scoring interno para fortalecer la calidad de las nuevas colocaciones.

EDA y correlaciones

- Diseñar estrategias de financiación diferenciadas considerando atributos académicos y demográficos
- Detectar segmentos críticos donde se concentran mayores tasas de mora para focalizar acciones institucionales.

Dashboard

- Monitorear en tiempo real el impacto del modelo sobre el indicador de recaudo oportuno (base 85%).
- Facilitar la toma de decisiones con tableros interactivos que integren métricas de predicción y resultados de gestión.

La combinación de análisis descriptivo, ingeniería de características y modelos supervisados constituye la estrategia más adecuada para resolver la problemática institucional.

Asimismo, la integración del modelo en un dashboard permite que los resultados sean accionables, transparentes y útiles para las áreas responsables, fortaleciendo la toma de decisiones basada en datos.

Ejecución

La fase de Configuración y Construcción constituye el momento en el que el proyecto pasa del diseño conceptual y analítico a la implementación técnica concreta del modelo predictivo de morosidad estudiantil. A diferencia de las fases anteriores, aquí se establecieron los plantemientos de los procedimientos, configuraciones y artefactos necesarios para materializar el modelo supervisado, garantizar su reproducibilidad y preparar los insumos que alimentarán la siguiente etapa: Monitoreo y Control.

Esta fase se estructuró en cinco componentes principales:

- Preparación del pipeline de datos
- Entrenamiento de modelos base y experimentación supervisada
- Gestión y trazabilidad de experimentos con MLflow en Databricks
- Búsqueda y optimización de hiperparámetros
- Selección del modelo final y definición de métricas para monitoreo

Cada componente se plantea a continuación con un nivel de detalle operativamente alineado con lo que se implementará en el ambiente analítico de la universidad.

Preparación del pipeline de datos para entrenamiento

La primera fase de ejecución se concentró en la construcción de un pipeline estandarizado, reproducible y libre de fugas de información que permita preparar los datos estudiantiles y crediticios de forma coherente con las mejores prácticas en modelos de riesgo financiero.

Esto posterior a la limpieza debido a que puede ocurrir el ingreso de nuevos datos que no estén estandarizados y evitar que pasen nulos al modelo hasta el momento que se pueda hacer nuevamente una revisión y limpieza de los datos y el reentrenamiento del modelo

Este pipeline incluyó:

Tipificación de variables

Se clasificó cada campo en categorías:

- Numéricas (cuotas, valor de financiación, antigüedad en meses, tasas, ingresos, valores cuantitativos).
- Categóricas (estrato, facultad, programa, modalidad, tipo de estudiante, cohorte, estado del crédito).
- Fechas y temporales (fecha de aprobación, fecha de vencimiento, edad de cartera).

El objetivo fue asegurar un tratamiento diferenciado y apropiado en cada etapa del modelado.

Imputación diferenciada

Se implementó un esquema de imputación robusto:

- Numéricas: imputación por mediana (menos sensible a valores extremos).
- Categóricas: imputación por moda y asignación explícita de categorías infrecuentes o desconocidas.

Este proceso fue ajustado únicamente sobre el conjunto de entrenamiento para evitar fugas de información.

Codificación categórica con One-Hot Encoding

Se implementó un OneHotEncoder con:

- Manejo de categorías raras mediante `min_frequency ~1%`.
- Evitación de explosión de dimensionalidad.
- Estandarización de niveles categóricos arrastrados desde Banner e ICEBERG.

ColumnTransformer

Se definió un ColumnTransformer que orquestó:

- Imputaciones,
- Codificaciones,
- Escalamiento cuando aplique,
- Representación matricial eficiente (sparse matrices).

Validación del pipeline

Antes de entrenar modelos, el pipeline fue probado para:

- Comprobar la ausencia de fugas,
- Validar formatos finales,
- Confirmar compatibilidad con los algoritmos seleccionados.

El objetivo fue asegurar un tratamiento diferenciado y apropiado en cada etapa del modelado.

Entrenamiento de modelos base y experimentación supervisada

En esta etapa se entrenaron diversos modelos con el propósito de evaluar su desempeño, estabilidad y capacidad predictiva en el contexto del riesgo crediticio estudiantil.

Modelos considerados:

Random Forest (bagging)	• Robusto ante ruido, valores faltantes y no linealidades. • Favorece interpretabilidad vía importancia de variables.
XGBoost (gradient boosting)	• Adecuado para relaciones complejas y estructuras altamente no lineales. • Tiende a ofrecer AUC altos, incluso en bases desbalanceadas.
LightGBM (boosting eficiente)	• Excelente desempeño con grandes volúmenes de datos categóricos. • Entrenamiento rápido y reducción eficiente de sesgo y varianza.
Versiónes con selección de variables (PSA y Boruta)	• Permitieron evaluar impacto de la reducción de dimensionalidad. • Favorecen interpretabilidad para la toma de decisiones financieras.
Modelos base comparativos :	• Regresión logística multinomial. • Métodos baseline para medir el valor agregado de algoritmos más complejos.

Esquema de validación

- Validación cruzada estratificada (k-fold)
- Prioridad evaluativa en:
- AUC macro One-vs-Rest
- Recall macro, especialmente la clase alto riesgo
- Precisión macro
- Exactitud

El objetivo fue garantizar que el modelo elegido tenga un desempeño estable y balanceado entre sensibilidad y capacidad discriminativa.

Experimentación sistemática con MLflow en Databricks

Durante esta fase se implementó un sistema de trazabilidad completa que permita gestionar, comparar y validar todos los experimentos generados.

Registro automático de métricas: Cada ejecución almacenó en MLflow:

- AUC macro
- Accuracy
- Recall macro
- Precision macro
- Resultados por clase
- Matrices de confusión

Registro de hiperparámetros y versiones: Se trazó:

- n_estimators
- max_depth
- min_samples_leaf
- max_features
- parámetros avanzados para XGBoost y LightGBM

Versionamiento de artefactos: MLflow mantuvo los artefactos del modelo, incluyendo:

- pipeline completo,
- modelo entrenado (.pkl),
- gráficos de desempeño,
- reportes de validación.

Comparación estructurada de ejecuciones

La plataforma permite revisar:

- cuál versión presenta mayor estabilidad,
- cómo afectan los hiperparámetros el desempeño, y cuáles combinaciones resultan óptimas

Tabla 9. Planteamiento de modelos a implementar

Optimización de Hiperparámetros

Una vez definidas las versiones base de los modelos candidatos, se llevó a cabo un proceso exhaustivo de optimización enfocado en maximizar el desempeño general del sistema de clasificación. Este proceso fue clave para refinar la capacidad predictiva del modelo, especialmente en un contexto como el de riesgo crediticio estudiantil, donde la correcta identificación de los casos de alto riesgo tiene un impacto directo sobre la sostenibilidad financiera de la institución. La optimización buscó no solo mejorar las métricas globales, sino también asegurar estabilidad, interpretabilidad y robustez frente a diferentes particiones de los datos.

Como estrategia principal de búsqueda de hiperparámetros se utilizó RandomizedSearchCV, debido a su eficiencia al explorar espacios amplios sin el costo computacional de un grid search tradicional. Mediante esta técnica se evaluaron variaciones controladas de la profundidad de los árboles, el número total de estimadores, el mínimo de muestras por nodo, la fracción de características disponibles en cada división y otros parámetros propios de métodos basados en boosting. Este proceso permitió identificar combinaciones que equilibren adecuadamente la reducción de varianza y la contención del sobreajuste, especialmente relevantes en bases con desbalance como la de morosidad estudiantil.

Cada configuración generada por el procedimiento de búsqueda fue evaluada mediante validación cruzada, con el fin de analizar su estabilidad y capacidad de generalización. La evaluación se centró no solo en el desempeño promedio, sino también en la consistencia de las métricas entre particiones, la discriminación por clase y la capacidad del modelo para identificar correctamente a los estudiantes con mayor probabilidad de incumplimiento. Este enfoque permitió seleccionar modelos que no solo obtienen altos puntajes de AUC o precisión, sino que mantienen comportamientos confiables y reproducibles ante diferentes distribuciones de los datos.

A partir de los resultados almacenados y comparados en MLflow, se realizó un proceso adicional de refinamiento sobre el modelo que muestre el mejor desempeño global. Esta etapa priorizó la reducción de falsos negativos en la categoría de alto riesgo, debido a que estos casos representan las mayores pérdidas potenciales para la institución. Para ello, se ajustaron umbrales de probabilidad, pesos de las clases y configuraciones finas del modelo previamente seleccionado.

De este modo, el proceso de optimización no solo se construyó un modelo preciso, sino que también garantizó que su comportamiento esté alineado con los objetivos estratégicos del proyecto de morosidad.

Selección del Modelo Final y Definición de Métricas para Monitoreo

El cierre de esta fase contempló seleccionar el modelo final y establecer las métricas oficiales de seguimiento.

Selección del modelo

El modelo fue seleccionado en función de:

- AUC macro,
- Recall macro,
- Estabilidad entre folds,
- Interpretabilidad para las áreas de Cartera y Financiera, coherencia con la lógica del riesgo crediticio.

Métricas oficiales de Monitoreo y Control

La fase definió las métricas que sirvieron como insumo para el tablero institucional:

- Métrica oficial: AUC macro
- Métrica complementaria crítica: Recall macro (alto riesgo)
- Métricas operativas: precisión, exactitud y estabilidad por clase

Entregables finales de esta fase

Al finalizar esta etapa se dispuso de:

- Modelo final validado,
- Pipeline técnico completo,
- Artefactos versionados en MLflow,
- Reportes de comparación de modelos,
- Documentación técnica detallada,
- Insumos para la siguiente fase

Modelos desarrollados y evaluación

A continuación se tipificaron las variables en numéricas y categóricas para habilitar un preprocesamiento diferenciado. En las numéricas se aplicó imputación por mediana; en las categóricas, imputación por la moda y codificación One-Hot con manejo de categorías poco frecuentes y desconocidas en inferencia (min_frequency cercano a 1 %). Todo el flujo se implementó con un ColumnTransformer (garantiza consistencia, eficiencia y uso de matrices esparsas cuando corresponde).

```
# Normaliza encabezados
df = df.copy()
df.columns = (
    df.columns.astype(str)
    .str.replace('\ufeff', '', regex=False)
    .str.strip()
)

# 1) Separar Y y X
TARGET = "Y_categoria"
DROP = ["Llave2", "Nombre_linea", "IDBANNER"]
y = df[TARGET].copy()
X = df.drop([TARGET] + [c for c in DROP if c in df.columns], axis=1).copy()

# 2) Columnas numéricas / categóricas
num_cols = [c for c in X.columns if pd.api.types.is_numeric_dtype(X[c])]
cat_cols = [c for c in X.columns if c not in num_cols]

# 3) Preprocesamiento
num_tf = SimpleImputer(strategy="median")
cat_tf = Pipeline(steps=[
    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("onehot", OneHotEncoder(
        handle_unknown="ignore",
        sparse_output=True,
        min_frequency=0.01,
        dtype=np.float32
    ))
])

preprocess = ColumnTransformer(
    transformers=[
        ("num", num_tf, num_cols),
        ("cat", cat_tf, cat_cols),
    ],
    remainder="drop",
    sparse_threshold=1.0
)

# 4) Partición
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y
)

# Validación del preprocesador
_ = preprocess.fit(X_train, y_train)

print("X:", X.shape, "| y:", y.shape)
print("Numéricas:", len(num_cols), "| Categóricas:", len(cat_cols))
print("Train:", X_train.shape, "Test:", X_test.shape)
```

```
preprocess = ColumnTransformer(
    transformers=[
        ("num", num_tf, num_cols),
        ("cat", cat_tf, cat_cols),
    ],
    remainder="drop",
    sparse_threshold=1.0
)

# 4) Partición
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y
)

# Validación del preprocesador
_ = preprocess.fit(X_train, y_train)

print("X:", X.shape, "| y:", y.shape)
print("Numéricas:", len(num_cols), "| Categóricas:", len(cat_cols))
print("Train:", X_train.shape, "Test:", X_test.shape)
```

Figura 13. Código de Procesamiento

La evaluación se estructuró con una partición estratificada 80/20 entre entrenamiento y prueba (el preprocesador se ajustó solo con entrenamiento y se validó su funcionamiento antes del modelado). Dado que se trata de un problema multiclase de morosidad, se priorizó el AUC macro One-Vs-Rest en validación cruzada y prueba, complementado con exactitud, precisión macro y recall macro (métricas sensibles al desbalance).

Esta configuración permitió controlar la heterogeneidad y el desbalance, evitar fugas de información y mantener pipelines reproducibles para la experimentación y el despliegue.

Los hallazgos de correlación guiaron la priorización de familias de variables (temporales, condiciones del crédito, montos y modalidades) y motivaron el uso de métodos de ensamble basados en árboles (son adecuados para relaciones no lineales e interacciones, son robustos ante escalas heterogéneas y valores faltantes y producen probabilidades útiles para segmentación por riesgo).

La combinación de bosques aleatorios (bagging) y boosting (XGBoost y LightGBM) permite contrastar sesgo y varianza; además, los esquemas de selección de características como PSA y Boruta contribuyen a simplificar y estabilizar los modelos (favorecen la interpretabilidad y el mantenimiento en un contexto de negocio).

Se desarrollaron cinco modelos predictivos de morosidad, cada uno en un notebook independiente, con el propósito de visualizar y comparar su desempeño bajo distintos enfoques de modelado y selección de variables.

En todos los casos se aplicaron esquemas de búsqueda aleatoria de hiperparámetros (RandomizedSearchCV) y validación cruzada estratificada, optimizando el AUC macro bajo el enfoque One-Vs-Rest. De esta manera se buscó determinar cuál de los modelos ofrecía el mejor equilibrio entre capacidad discriminativa, estabilidad y generalización.

Modelo 1. Random Forest con RandomizedSearchCV

El primer modelo correspondió a un bosque aleatorio entrenado con ponderación balanceada para controlar el desbalance de clases. En el pipeline se incluyó imputación y codificación ordinal de variables categóricas. Se utilizó validación cruzada estratificada con tres particiones, optimizando el AUC macro One-Vs-Rest.

Los resultados entregaron el mejor conjunto de hiperparámetros, las métricas en la muestra de prueba, un reporte detallado por clase y las probabilidades de pertenencia a cada categoría de riesgo. Este algoritmo se seleccionó como línea base por su estabilidad frente al ruido y su capacidad para proporcionar medidas de importancia de variables, útiles para interpretación y lectura gerencial.

Modelo 2. XGBoost con RandomizedSearchCV

El segundo modelo se basó en XGBoost, un método de boosting de gradiente aplicado con imputación y codificación ordinal. La búsqueda aleatoria exploró parámetros como profundidad de los árboles, tasa de aprendizaje, pesos mínimos por nodo, parámetro gamma y tasas de muestreo. La validación cruzada fue estratificada y se optimizó el AUC macro.

El modelo arrojó la mejor configuración de hiperparámetros y métricas en prueba. XGBoost fue elegido por su capacidad para manejar relaciones no lineales y estructuras complejas entre variables, logrando buena discriminación incluso en escenarios con cierto desbalance.

Modelo 3. LightGBM con RandomizedSearchCV

El tercer modelo empleó LightGBM bajo la misma estructura de preprocesamiento. Se exploraron hiperparámetros como número de hojas, profundidad máxima, muestras mínimas por nodo, tasa de aprendizaje y regularizaciones. También se utilizó validación cruzada estratificada optimizando el AUC macro.

LightGBM se destaca por su eficiencia al procesar grandes volúmenes de datos y categorías, con tiempos de entrenamiento reducidos y un buen equilibrio entre sesgo y varianza, lo que lo convierte en una alternativa ágil y precisa.

Modelo 4. PSA (selección por modelo) con competencia RF, XGB y LGBM

El cuarto modelo incorporó una fase de selección de características mediante la técnica PSA (SelectFromModel) utilizando LightGBM como estimador base. Este procedimiento retuvo únicamente las variables con importancia superior a la mediana.

A partir de ese subconjunto reducido, se entrenaron tres modelos (Random Forest, XGBoost y LightGBM), que fueron comparados en validación cruzada y prueba con base en el AUC macro One-Vs-Rest, además de precisión y recall.

Esta estrategia permitió reducir la dimensionalidad, mejorar la interpretabilidad y agilizar el proceso de entrenamiento, manteniendo un nivel competitivo de desempeño.

Modelo 5. Boruta con competencia RF, XGB y LGBM

El quinto modelo utilizó el método Boruta para la selección de variables, tomando un Random Forest como estimador guía. Boruta identificó de manera estable las variables confirmadas como relevantes frente a permutaciones aleatorias.

Este subconjunto se aplicó luego a los pipelines finales mediante una transformación que preservó solo las columnas seleccionadas. Los modelos resultantes (BORUTA+RF, BORUTA+XGB y BORUTA+LGBM) se compararon según el AUC macro, exactitud, precisión y recall.

Boruta se destacó por su capacidad para identificar relevancia real de las variables y mitigar efectos de colinealidad, especialmente en bases con muchas variables categóricas.

Feature selection

El análisis de Boruta destacó variables coherentes con la lógica de morosidad crediticia.




Figura 14. Feature Selection

- Tipo_interes refleja la modalidad de cobro, cuyas condiciones afectan la capacidad de pago.
- Antigüedad_meses resume la trayectoria del crédito y su comportamiento a lo largo del tiempo.
- Cuotas define la exigencia mensual y el horizonte de exposición al riesgo.
- TIPOESTUDIANTE se relaciona con la permanencia académica, mientras que
- Fecha_aprobacion, Mes y AñoB incorporan el componente temporal y de cohortes.
- Cohorte y CARGA representan condiciones académicas y operativas que pueden incidir en la capacidad de cumplimiento.
- Variables como Valor_financiacion, Valor_primera_cuota, Valor_cuota_inicial y Validación valor financiado cuantifican el compromiso financiero, y
- PROGRAMA, FACULTAD, Vr_neto_matricula completan el perfil académico y socioeconómico del estudiante.

En conjunto, estas variables coinciden con los patrones observados en los análisis de correlación y respaldan la importancia de los factores temporales, las condiciones del crédito y las características académicas en la clasificación del riesgo.

Las metodologías PSA y Boruta, guiadas por estos hallazgos, permitieron concentrar el modelado en los factores de mayor capacidad explicativa, reduciendo ruido y redundancia y mejorando la estabilidad general de los modelos.

Evaluación de resultados y resumen de modelos

Modelo	Metodología	AUC_test	AUC_CV	Δ AUC (Test-CV)	Accuracy	Precision_macro	Recall_macro
RF	Random Forest (tuned)	0.82	0.81	0.01	0.86	0.47	0.47
XGBoost	XGB (tuned)	0.85	0.84	0.01	0.89	0.45	0.34
LightGBM	LGBM (tuned)	0.84	0.83	0.01	0.89	0.46	0.34
PSA + XGB	PCA/PSA + XGB	0.83	0.81	0.01	0.89	0.82	0.34
BORUTA + XGB	Boruta + XGB	0.83	0.82	0.02	0.89	0.49	0.34




Figura 15. Evaluacion de Resultados

A partir del comparativo, todos los enfoques muestran brechas pequeñas entre el AUC en validación cruzada y el AUC de prueba (aprox. 0.01–0.02), lo que sugiere modelos estables sin sobreajuste relevante. XGBoost presenta el mayor AUC_test (0.85), seguido por LightGBM (0.84) y Random Forest (0.82). En términos de exactitud, los métodos de boosting superan levemente a Random Forest (aprox. 0.89 frente a 0.86), y en precisión macro las diferencias son reducidas, entre 0.45 y 0.49, con excepción del pipeline PSA+XGB que destaca en precisión, aunque sin mejorar la capacidad de detección.

Bajo el objetivo del proyecto, identificar con oportunidad los casos de mayor riesgo, se prioriza el recall macro porque mide la capacidad del modelo para recuperar verdaderos positivos en todas las clases, especialmente en la categoría de riesgo alto. En este criterio, Random Forest obtiene el mejor resultado (0.47), superando de manera clara a XGBoost y LightGBM (0.34). Además, RF presenta la menor diferencia entre AUC en prueba y validación cruzada (aprox. 0.01), lo que refuerza su estabilidad fuera de muestra. En consecuencia, aunque XGBoost alcanza el AUC más alto, se selecciona Random Forest como modelo de referencia por ofrecer un mejor equilibrio entre capacidad discriminativa, estabilidad y mayor recall.

Este comportamiento indica que logra capturar de forma más efectiva las diferentes categorías, y en especial la de riesgo alto, que es la más relevante para la toma de decisiones en estrategias de cobranza y prevención. Además, Random Forest aporta interpretabilidad mediante la importancia de variables, facilitando la comprensión y el seguimiento del riesgo. Por último, los enfoques con selección de variables (PSA y Boruta) no mejoraron significativamente el desempeño global frente a las versiones ajustadas, por lo que se recomienda mantener RF como base y utilizar los resultados de selección de variables como apoyo explicativo y de gobernanza del modelo.

Luego de determinar que el modelo Random Forest representaba la mejor alternativa, se procedió a continuar el proceso de experimentación en una herramienta de seguimiento y gestión de modelos del tipo MLflow, en este caso Databricks. Allí se registraron los experimentos realizados, permitiendo documentar las métricas, los hiperparámetros y las versiones del modelo de manera estructurada y reproducible.

https://dbc-75a70282-d4ac.cloud.databricks.com/ml/experiments/4331751283863737/runs?o=3079939572844565&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&startTime=ALL&lifecycleFilter=Active&modelVersionFilter=All+Runs&datasetsFilter=W10%3D

Resultados del Modelo LightGBM

Todos los experimentos y ejecuciones de los modelos fueron desarrollados en Databricks, utilizando MLflow para el registro de métricas, seguimiento de experimentos y comparación de resultados. En este entorno se entrenó el modelo LightGBM (LGBM), cuyos resultados mostraron un desempeño moderado frente al problema de clasificación del riesgo crediticio.

El AUC promedio del modelo se ubicó entre 0.77 y 0.79, lo que evidencia una capacidad limitada para discriminar adecuadamente entre los niveles de riesgo. Aunque la exactitud (accuracy) alcanzó valores cercanos a 0.89, este indicador puede estar influenciado por el desbalance de clases, por lo que no necesariamente refleja un buen poder predictivo. Las métricas de desempeño por clase refuerzan esta lectura: el precision_macro osciló entre 0.54 y 0.64, mientras que el recall_macro se mantuvo alrededor de 0.35, indicando que LightGBM tuvo dificultades para identificar correctamente las clases minoritarias y capturar patrones relevantes en el dataset.

En conjunto, estos resultados posicionan a LGBM como el modelo con menor rendimiento entre los tres algoritmos evaluados, sirviendo como punto de comparación para los siguientes modelos: XGBoost y Random Forest.




Figura 16. Resultados del Modelo LightGBM

Resultados del Modelo XGBoost

El modelo XGBoost también fue entrenado y evaluado dentro del entorno de Databricks, utilizando MLflow para registrar los experimentos y comparar las métricas entre ejecuciones. Este modelo mostró un desempeño superior al alcanzado por LightGBM, especialmente en términos de discriminación entre clases y métricas de precisión. El AUC promedio osciló entre 0.76 y 0.81, alcanzando picos de 0.81, lo que refleja una capacidad más robusta para separar correctamente los diferentes niveles de riesgo crediticio.

Si bien la exactitud (accuracy) se mantuvo igual a LightGBM (alrededor de 0.89), las mejoras más notables se evidenciaron en el precision_macro, donde XGBoost logró valores entre 0.66 y 0.85, superando ampliamente el desempeño del modelo anterior. Esto indica que XGBoost clasifica con mayor certeza cuando predice una clase, especialmente en las categorías menos representadas. Por otro lado, el recall_macro permaneció cercano a 0.35–0.36, lo cual confirma que, aunque XGBoost es más preciso, aún enfrenta desafíos para capturar casos positivos de clases minoritarias. En conjunto, estos resultados posicionan a XGBoost como un modelo intermedio sólido, con una mejora clara frente a LGBM pero todavía por debajo del desempeño final obtenido con Random Forest.




Figura 17. Resultados del Modelo XGBoost

Resultados del Modelo Random Forest

El modelo Random Forest, entrenado y monitoreado en Databricks mediante MLflow, obtuvo el mejor desempeño entre los tres algoritmos evaluados. En términos de discriminación, alcanzó un AUC promedio entre 0.82 y 0.83, superando consistentemente los valores obtenidos con LGBM y XGBoost. Esta métrica evidencia una capacidad más robusta del modelo para diferenciar correctamente entre los distintos niveles de riesgo crediticio.

Si bien la exactitud (accuracy) se mantuvo en rangos similares a los otros modelos (entre 0.86 y 0.87), las mejoras más importantes se reflejaron en métricas asociadas al desempeño por clase. El `precision_macro` se ubicó entre 0.44 y 0.48, y aunque es ligeramente inferior al de XGBoost, el `recall_macro` mostró valores superiores (hasta 0.57 en algunas ejecuciones), convirtiendo a Random Forest en el modelo con mayor capacidad para detectar correctamente las clases minoritarias. Esta mejora en sensibilidad lo posiciona como el modelo más equilibrado en términos de precisión y recall, y por tanto, el más adecuado para un caso real de riesgo crediticio donde los falsos negativos son críticos.




Figura 17. Resultados del Modelo Random Forest

Random Forest logró el mejor equilibrio general: alcanzó el AUC más alto, mantuvo un buen nivel de precisión y demostró la mejor capacidad para identificar correctamente las clases minoritarias mediante un recall superior.

Este balance entre métricas lo convierte en el modelo más estable y confiable para un sistema de clasificación de riesgo crediticio, donde la correcta identificación de estudiantes con mayor probabilidad de incumplimiento es fundamental para la toma de decisiones institucionales.

Ajustes realizados durante el proyecto

Durante el desarrollo del proyecto se identificaron y aplicaron ajustes relevantes al tratamiento de los datos, al enfoque de modelado y al esquema general de la solución, como resultado de la evaluación empírica de alternativas frente a los requerimientos del negocio.

Ajuste 1. Descarte de PCA como técnica de reducción de dimensionalidad:

En una fase previa (anteproyecto) se evaluó si era pertinente incorporar el Análisis de Componentes Principales como técnica formal de reducción de dimensionalidad, comparando el desempeño de modelos entrenados con y sin PCA sobre las variables numéricas reales del dataset. El análisis mostró que las variables numéricas no presentaban correlaciones suficientes como para beneficiarse de esta técnica: los componentes generados agrupaban únicamente el comportamiento socioeconómico (Valor Máximo, Medio y Bajo) y los valores financieros del crédito, mientras que variables como Cuotas y Antigüedad permanecían prácticamente aisladas en sus propios componentes (Figuras 7 y 8).

Adicionalmente, los modelos sin PCA obtuvieron mejor desempeño en las métricas críticas —AUC, precisión y recall—, especialmente en la identificación de las clases minoritarias de riesgo Alto y Medio (Figura 9). Por esta razón se decidió descartar PCA y mantener únicamente la depuración de variables irrelevantes, constantes o con bajo aporte analítico, en línea con las tendencias de los modelos de riesgo estudiantil del sector. Como resultado, se conservan 41 variables interpretables y mejora la detección de riesgo Alto y Medio.

Ajuste 2. Descarte de K-Means como definición de la variable objetivo:

De forma similar, se exploró inicialmente el uso de K-Means como técnica de segmentación no supervisada, con el objetivo de identificar agrupaciones naturales en los créditos que pudieran relacionarse con el riesgo real observado. Los resultados (método del codo y distribución por clusters, Figuras 15 y 16) permitieron identificar tres grupos naturales de financiamiento, diferenciados por antigüedad del crédito, monto financiado, valor de matrícula y niveles de scoring externo.

Sin embargo, se evidenció que estos clusters agrupaban créditos similares financieramente y no créditos similares en riesgo, por lo que no se alineaban con el comportamiento real de la mora. Esto se debe a que K-Means opera únicamente sobre variables numéricas y no incorpora los factores académicos, demográficos y conductuales que realmente explican el riesgo, los cuales residen en las variables categóricas. Por esta razón se decidió descartar la segmentación por clustering como base de la variable objetivo, conservándola únicamente como herramienta

exploratoria y para construir los clusters de programa usados como filtro del tablero, y avanzar con la clasificación de riesgo (Y categórica: Alto/Medio/Bajo) definida mediante reglas de negocio y validada directamente con el stakeholder del área de Cartera, la cual sí incorpora el conocimiento del dominio y quedó como base del enfoque de modelado supervisado finalmente implementado.

Ajuste 3. Redefinición del alcance del tablero:

Las sesiones de revisión de datos con los stakeholders evidenciaron que la base de cartera debía utilizarse exclusivamente como insumo para la construcción de la variable objetivo del modelo, y no como componente visible del tablero. Este ajuste cumple una doble función: evita el riesgo de fuga de información hacia el modelo y responde a la necesidad del negocio de contar con una vista clara de los créditos vigentes con su nivel de riesgo predicho, en lugar del detalle operativo de cuotas que ya está disponible en los sistemas transaccionales. Como resultado, se obtiene un visualizador más sintético, centrado en la predicción del riesgo y no en el detalle operativo de cuotas.

Ajuste 4. Cambio de la herramienta de visualización

El planteamiento inicial contemplaba un dashboard implementado en Power BI. Durante la fase de construcción se optó por desarrollar la aplicación en Streamlit, en coherencia con el criterio de éxito de recursos, que establece la ejecución del proyecto aprovechando herramientas open source y la infraestructura institucional disponible, sin licencias adicionales. Adicionalmente, Streamlit permitió incorporar la carga de nuevos archivos CSV con predicción en línea, funcionalidad que la alternativa inicial no habilitaba de forma directa. Con esto se cumple la restricción de costo y se habilita la carga de nuevos archivos con predicción en línea.

Oportunidades de mejora identificadas

Además de los ajustes ya implementados, la evaluación de resultados permitió identificar tres oportunidades de mejora que no se ejecutaron en esta versión y que quedan priorizadas en el plan de cierre.

En primer lugar, revisar con el área de Cartera el ancho de la banda correspondiente al nivel de riesgo Medio (0.20 a 0.25), o reformular el problema como binario Alto frente a No-Alto, dado que la clase Medio concentra apenas el 0,7 % de los registros y penaliza de forma desproporcionada las métricas macro sin aportar valor operativo diferenciado.

En segundo lugar, ejecutar el ajuste fino de umbrales de probabilidad y pesos de clase orientado a maximizar el recall de la clase Alto, sobre el modelo Random Forest ya entrenado, con el fin de aproximarse al umbral comprometido de 0.75 en el requerimiento DE-03. Finalmente, registrar y documentar el F1-Score macro y el reporte de desempeño por clase del modelo final, métricas comprometidas en MO-02 y EV-02 que no quedaron consignadas en la versión actual del experimento.

Tablero Desarrollado

El visualizador actual presenta cambios significativos respecto al mockup inicialmente diseñado, resultado de las sesiones de revisión de datos realizadas con los stakeholders. En estas reuniones se evidenció que la base de cartera debía utilizarse exclusivamente como insumo para la construcción de la variable objetivo del modelo y no como componente visible del tablero, lo que llevó a consolidar un visualizador más sintético, centrado en la predicción del riesgo y no en el detalle operativo de cuotas.

El diseño final responde directamente a las necesidades del negocio: ofrecer una vista clara de los créditos vigentes con su nivel de riesgo predicho, permitiendo al equipo de cartera priorizar casos, orientar estrategias de gestión preventiva y tomar decisiones más efectivas para mitigar la morosidad y generar rutas para gestión de cobro.

https://juan-crss-prediccion-morosidad-es-dashboardsreamlit-app-fpwpdpx.streamlit.app




Figura 18. Tablero Desarrollado

El dashboard permite al usuario visualizar y analizar el riesgo de morosidad de los créditos estudiantiles. Al ingresar, encuentra un encabezado con la fecha de actualización y una descripción general del propósito del tablero. Puede cargar nuevos archivos CSV con observaciones adicionales; el sistema envía estos datos a la API del modelo, obtiene el nivel de riesgo para cada registro y actualiza automáticamente todas las visualizaciones.

El usuario dispone de múltiples filtros para explorar la información: búsqueda por nombre, nivel de riesgo predicho, rango de fechas de aprobación, tipo de cliente, facultad y programa, además de versiones agrupadas en segmentos (clusters) que permiten análisis más estables. Estos filtros afectan todo lo que se muestra en el tablero.

El tablero presenta indicadores principales como número total de créditos filtrados, cantidad y porcentaje de créditos en riesgo alto, porcentaje de créditos en mora real según Datacrédito y montos financiados totales y por categoría de riesgo. Estos KPIs permiten dimensionar tanto el volumen como la exposición económica de la cartera bajo los criterios seleccionados.

Más abajo se incluyen gráficos interactivos que muestran: distribución de créditos por nivel de riesgo, evolución del número de cuotas promedio según mes y categoría de riesgo, un mapa de calor del porcentaje de mora por segmento de programa y año, la mezcla de niveles de riesgo en el tiempo y un mapa geográfico con la ubicación de los créditos según su clasificación de riesgo. Cada gráfico se ajusta dinámicamente con los filtros elegidos.

Finalmente, se presenta una tabla con los créditos en mora reportados por Datacrédito, mostrando para cada caso el nombre, programa, fecha de aprobación, nivel de riesgo predicho, probabilidad estimada si está disponible y el número de créditos activos por estudiante. Esto permite revisar casos críticos y compararlos con la clasificación del modelo.

Principales resultados y conclusiones

El proyecto logró consolidar un modelo predictivo robusto para anticipar la morosidad en créditos estudiantiles mediante la integración de más de 70 variables provenientes de fuentes académicas, financieras y crediticias. Tras un riguroso proceso de limpieza, imputación y aseguramiento de la calidad (que incluyó 147 reglas de validación y 75 transformaciones) se construyó un dataset consistente, sin fugas de información y centrado exclusivamente en variables disponibles al momento del otorgamiento del crédito.

En la fase de modelado, los métodos de ensamble basados en árboles fueron los que mejor desempeño demostraron. Aunque XGBoost alcanzó el mayor AUC en la muestra de prueba, se determinó que Random Forest ofrecía el equilibrio más adecuado entre capacidad discriminativa, estabilidad y recuperación de los casos de mayor riesgo. Su recall macro superior y la mínima diferencia entre validación y prueba evidenciaron una excelente generalización. Al profundizar la experimentación en Databricks, la versión optimizada del modelo obtuvo métricas sólidas como accuracy de 0.873, AUC macro de 0.822 y precisión macro de 0.478, consolidándolo como la alternativa más apropiada para el despliegue institucional.

El desarrollo del tablero analítico permitió convertir el modelo en una herramienta operativa de alto valor para la gestión preventiva de cartera. Este visualizador, refinado a partir de la retroalimentación de los stakeholders, facilita la segmentación, el seguimiento y la priorización de créditos según su nivel de riesgo predicho, integrando indicadores clave, análisis temporales, segmentación académica y una vista geográfica. El resultado es una solución práctica y orientada a la acción, capaz de fortalecer la sostenibilidad financiera institucional mediante decisiones más informadas, oportunas y enfocadas.

Finalmente, el proyecto responde de manera directa a la pregunta de negocio: cómo anticipar el riesgo de morosidad para mejorar la gestión de cartera y proteger la salud financiera de la universidad. La solución transforma un proceso tradicionalmente reactivo en un enfoque predictivo, permitiendo identificar con antelación a los estudiantes con mayor probabilidad de incumplir, asignar recursos de seguimiento de manera más eficiente y habilitar estrategias de cobranza preventivas. Este valor agregado se traduce en menor deterioro de cartera, mejor planeación financiera y una gestión más estratégica del crédito estudiantil.

Componentes pendientes y plan de implementación

El alcance de la primera versión priorizó el modelo predictivo y el tablero de seguimiento. Durante el desarrollo se identificaron los siguientes componentes pendientes, agrupados según su nivel de criticidad para la entrega del prototipo final.

Con criticidad **alta** se encuentran seis componentes. El ajuste de umbrales y pesos de clase para elevar el recall de la clase de riesgo alto (DE-03) tiene el modelo ya entrenado, pero el ajuste fino aún no se ha ejecutado. El registro del F1-Score macro y del reporte de desempeño por clase del modelo final (MO-02, EV-02) corresponde a métricas comprometidas que no quedaron consignadas en la versión final del experimento. La automatización del pipeline de extracción, transformación y predicción (DE-01) sigue pendiente, ya que la extracción desde Banner e ICEBERG y la carga de datos continúan siendo manuales, y se requiere al menos un ciclo probado.

La retroalimentación mensual y el disparador automático de reentrenamiento ante un AUC menor a 0.80 (ME-01) ya tienen su criterio definido, pero la automatización no ha sido implementada. La sesión formal de validación con experto y medición de satisfacción igual o superior al 80 % (EV-03) aún no se ha ejecutado. Finalmente, el control de acceso y autenticación del tablero desplegado está pendiente, dado que la aplicación es actualmente accesible mediante una URL pública sin restricción.

Con criticidad **media** se identifican cinco componentes. La revisión con el área de Cartera del ancho de la banda de riesgo Medio, o la reformulación del problema como binario, quedó identificada como oportunidad de mejora pendiente de ejecutar. La validación documentada del Top 10 de variables con el asesor financiero (MO-03) tiene el cálculo ya realizado, pero falta el acta de validación correspondiente.

La funcionalidad de exportación de resultados desde el tablero (DB-02) y la integración con el sistema de gestión de cartera (DB-04) no han sido implementadas. La ejecución automática de los controles de calidad sobre los datos de entrada (ME-02) tiene sus reglas definidas, pero actualmente se ejecutan de forma manual. Y la remediación de los 812 registros de CRq que incumplen la regla del 85 % de Vr_neto_matricula (DA-02) corresponde a un hallazgo ya detectado que aún no ha sido remediado.

Con criticidad **baja** quedan dos componentes: la generación automática de reportes periódicos (ME-03), que no ha sido implementada, y la generación de nuevas variables derivadas (DP-03), declarada explícitamente fuera del alcance de esta primera versión.

Plan para completar la implementación del prototipo funcional:

El plan se organiza en actividades secuenciales cuyos hitos están condicionados por la fecha de la evaluación del prototipo con los usuarios y por la fecha de la presentación ejecutiva.

Actividad 1: Ajuste de umbrales y pesos de clase; registro de F1 y desempeño por clase. Responsable: María Fernanda González. Entregable: Modelo v2 en MLflow + reporte de métricas completo. Inicio: 1 de agosto. Fin: 15 de agosto.

Actividad 2: Remediación de los 812 registros de CRq y automatización de los controles de calidad. Responsable: Carolina Fuentes Pulido. Entregable: Script de calidad ejecutable + log de remediación. Inicio: 1 de agosto. Fin: 20 de agosto.

Actividad 3: Automatización del pipeline ETL y del ciclo de predicción. Responsable: Renato Patiño Fierro. Entregable: Job programado + evidencia de un ciclo completo. Inicio: 15 de agosto. Fin: 5 de septiembre.

Actividad 4: Exportación de resultados y control de acceso en el tablero. Responsable: Juan Camilo Romero. Entregable: Tablero v2 con autenticación. Inicio: 20 de agosto. Fin: 10 de septiembre.

Actividad 5: Definición del disparador de reentrenamiento y esquema de monitoreo. Responsable: Rafael Negrete. Entregable: Documento de monitoreo y control. Inicio: 1 de septiembre. Fin: 15 de septiembre.

Actividad 6: Sesión de validación del Top 10 de variables con el asesor financiero. Responsable: Juan Camilo Romero. Entregable: Acta de validación (MO-03). Inicio: 5 de septiembre. Fin: 15 de septiembre.

Actividad 7: Evaluación del prototipo con usuarios de Cartera y Dirección Financiera. Responsable: María Fernanda González (equipo completo). Entregable: Casos de prueba DB-01 a DB-04 + encuesta (EV-03). Inicio: 16 de septiembre. Fin: 5 de octubre.

Actividad 8: Incorporación de hallazgos de la evaluación. Responsable: Carolina Fuentes Pulido. Entregable: Backlog de correcciones cerrado. Inicio: 6 de octubre. Fin: 15 de octubre.

Actividad 9: Alistamiento de entregables y documentación final. Responsable: Rafael Negrete. Entregable: Repositorio, documento técnico y anexos. Inicio: 16 de octubre. Fin: 25 de octubre.

Actividad 10: Preparación y ensayo de la presentación ejecutiva. Responsable: Renato Patiño Fierro. Entregable: Presentación ejecutiva. Inicio: 26 de octubre. Fin: 1 de noviembre.

Nota: las actividades 1 a 6 deben quedar cerradas antes de iniciar la actividad 7, ya que la evaluación del prototipo es el hito que condiciona el alistamiento de entregables y la presentación ejecutiva.

Criterios de aceptación de la evaluación del prototipo

- DB-01: 100 % de los casos de prueba de filtros superados.
- DB-02: 100 % de éxito en las pruebas de exportación con usuarios.
- DB-03: 100 % de los KPI exigidos presentes en la vista de resumen.
- DB-04: ≥ 90 % de casos de prueba de integración con el sistema de gestión de cartera.
- EV-03: al menos un experto validador con nivel de satisfacción ≥ 80 %.
- DE-02: plan de adopción acordado para alcanzar el 100 % del equipo de Cartera en tres meses.